

Agent 评估指标设计实验报告

1. 指标选取原因

为了客观、全面且精准地衡量大模型（Agent）在执行复杂工具调度和任务委托（如餐厅查询、建单、支付等）过程中的能力边界和短板，本实验并未采用单一的对比机制，而是从微观、中观和宏观三种颗粒度选取了具有层次依赖关系的三个维度的评估指标：

1. 工具调用准确度 (Tool Call Accuracy) (微观实现)：

Agent 正确履行职责的基石是能够调起预期工具并传入准确规范的参数。该指标严格检验 Agent 每一步 Action 序列是否与人类专家标注的标准轨迹匹配，以及传入的关键槽位提取是否出现幻觉或错漏。

2. 规划质量 (Planning Quality) (中观逻辑)：

面对具有强前后链路依赖的复杂业务（例如：获取店铺 -> 选择商品 -> 创建订单 -> 支付），Agent 会因果倒置或遗漏必要关节。该指标能够容忍一定程度的“工具重试兜底”，专门用来衡量模型逻辑思维的严密程度和对业务边界条件的尊重（比如识别和惩罚冗余操作或未建单先支付的违规操作）。

3. 目标达成率 (Goal Completion) (宏观结果)：

从实际用户体验角度触发，忽略过程损耗，只看两点：一是环境后端是否达成了业务预期（订单支付状态是否挂账改变等），二是系统返回给用户的最终话术（Final Answer）中是否提供了用户索求的核心信息（单号、地址等）。

2. 指标实现过程

结合 `evaluator/metrics.py` 的具体实现，三个维度的核心实现逻辑为：

2.1 ToolCallAccuracyMetric (工具调用准确度)

- 序列验证**：提取验证执行序列（`pred_sequence`）与真值序列（`ref_sequence`）的严格一致性。
- 参数字段对准**：通过预先维护字典 `KEY_FIELDS` 定义每个工具接口（如 `place_order` 的 `restaurant_id`, `items`, `delivery_address`）的必带核心参数。遍历对比实际输入和标答输入，计算字段命中数量和比例。
- 最终计算**：将字段完全匹配数量之比累加求平均得到 `average_arg_score`，再乘以覆盖率与序列对齐系数。只要执行顺序不对位往往此项会受到重罚。

2.2 PlanningQualityMetric (规划质量)

以规则嗅探的方式统计运行轨迹（`tasks_sample.steps`）的合规性：

- 前置依赖拦截**：如果工具序列包含 `search_products`，代码将自动向前追溯是否已经拿到了 `restaurant_id`；如果有 `pay_order`，检索前置轨迹验证是否有成功的 `order_id` 及两者是否一致。
- 缺失必选动作**：检查特定场景（如需要支付的单子缺乏 `pay_order` 或订单状态查询缺 `check_order_status`）。
- 冗余操作识别**：通过 `Counter` 收集同类工具与完全相同入参的调用序列来标记无意义的冗余请求。

- **分数计算**：满分 1.0 的基础上，对依赖性违规和关键步骤遗漏分别按 40% 的权重作削减，并对冗余步骤按 20% 衰减给分。

2.3 GoalCompletionMetric (目标达成度)

- **阶段流转识别**：利用对 `step.parsed_observation` 的解析，打标五个关键里程碑标志位，包含环境状态中的 `has_restaurant_result`、`order_created`、`payment_completed` 等标志真伪。针对当前特定的任务类型(`task_type`)进行强校验。
- **回答槽位提取**：调用 `extract_required_answer_slots` 寻找用户必需知道的结果片段，并校验 `sample.final_answer` 的字符串信息内容补全度。
- **分数叠加**：按照 $0.7 * \text{系统环境状态完成度} + 0.3 * \text{回复覆盖完整度}$ 产出本模块的分数。

3. 评估结果分析

基于 `results/summary.json` 提供的数据统计，本次针对 **27 条样本** 提取的定量评估报告结果如下：

3.1 总体数据表现

- **平均工具准确度 (Mean Tool Call Accuracy)**: 41.68%
- **平均规划质量 (Mean Planning Quality)**: 98.89%
- **平均目标达成率 (Mean Goal Completion)**: 87.41%
- **平均整体得分 (Mean Overall Score)**: 75.99%

错误类型统计分布：

- Missing Tools 工具漏调: 7 个
- Missing Required Steps 核心规划步骤缺失: 3 个
- Missing Answer Slots 输出槽位遗漏: 5 个

3.2 深度分析综合论点

1. Agent 具备优异的业务编排推理与泛化能力

评估指标中 `Planning Quality` 高达接近极值的 98.89%。Agent 能够近乎完美地遵守逻辑常识执行流程（如创建并拿着真实生成的 `order_id` 进行支付等），几乎从未发生错乱时序的破坏性行为，同时未报错的流程中，具有达到 87.41% 的 `Goal Completion`，证明大部分意图最终在后端业务系统都被成功消费并落库。

2. 严苛“工具调配微操”表现脆弱，拉低均分

该 Agent 主要扣分源自于低下的 `Tool Call Accuracy` (约 41.68%)。结合分析原因主要有：一是微调对齐问题（7 个 Missing Tools 和 3 个关键步骤断层导致长订单流失败率偏上，最低分为 36.67% 的样本全部集中在 `order_flow`），存在模型偶尔尝试合并没有暴露的方法或对接口细节产生幻觉。二是严格匹配规则下，少部分的合理等效绕路或者多轮工具探查被判断成了“参数匹配不一或者序列偏离”。

3. 关键信息传递的失流

部分案例出现了环境任务明明完成跑通了，但是没有向前端用户传回必要答案槽位信息（出现 5 次 Missing Answer Slots），这反映了模型可能陷入了“做事忘说话”的状态。

3.3 优化建议

1. 强化 **System Prompt** 中关于目标工具定义格式规范的约束，增强少量 One-shot 实例来约束其针对性提供精确 `KEY_FIELDS`，可大幅提高严苛比对中的工具对齐和调用准确度。
2. 提高结果总结阶段指引：要求 Agent 动作完成后，务必根据任务类型的结束意图（获取单号/获取追踪详情等），检查提取缓存里的数据并组装最终回复。