

Agent 评估系统 体系结构设计文档

文档作者

主要编写者：刘佳昱 刘怡然

目录

1. 引言

- 1.1 编制目的
- 1.2 词汇表
- 1.3 参考资料

2. 产品概述

3. 逻辑视角

4. 组合视角

- 4.1 开发包图
- 4.2 运行时进程
- 4.3 物理部署

5. 接口视角

- 5.1 模块的职责与层之间调用
- 5.2 用户界面层（RESTful HTTP API）
- 5.3 业务逻辑层（Services / SSE Consumer）
- 5.4 数据访问层（DAO / Models）

6. 信息视角

- 6.1 描述数据持久化对象(PO)
- 6.2 数据库表信息

1. 引言

1.1 编制目的

本报告详细完成对 **Agent 评估系统后端**的概要设计，达到指导详细设计和开发的目的，是了解该后端的整体蓝图与系统导航代码框架的核心参考。

1.2 词汇表

词汇名称	词汇含义	备注
Agent	智能体系统，本系统主要评估的目标对象（主要指文章事实核查Agent）	独立于本系统部署
SSE	Server-Sent Events (服务器推送事件)，用于实时接收Agent推理事件流	HTTP 单向数据流，用于实时追踪思考和工具调用过程
Pydantic / Schema	Python数据校验和序列化库，项目中定义为传输数据 (Schema/DTO)	输入验证，输出保障
PO / ORM	Persistent Object (持久化对象)，映射数据库表的后端实体类	基于 SQLAlchemy 定义，放在 `app.models`

2. 产品概述


Agent 评估系统后端的主要职能是**为一个（或多个）外置的 Agent（如事实核查 Agent）系统提供全套的评测流水线**。系统支持动态接入不同的 Agent（通过 Endpoint / Token 配置），挂载指定的测试用例文本数据集，下发批量调用指令后，建立 SSE 流实时记录 Agent 对给定输入的审查心智过程（Plan, Thinking, Tool Call）及最终的结论。

功能闭环： 环境准备 -> 配置数据集及验证用例 -> 触发跑批任务 -> 实时接收流记录 -> 自动指标生成 -> 展示最终报表 。

3. 逻辑视角

系统采用分层架构 (Layered Architecture)。采用自顶向下、单边依赖的结构，由 Controller（API 端点层）调度 Service（服务层），进而由 Service 发起对 Domain/DB 层的控制。

分层体系结构的逻辑设计方案图：




4. 组合视角

4.1 开发包图

表1 开发包设计

开发(物理)包	主要职能	依赖的其他开发包
app.api.v1	定义所有路由接入点（Controller），处理 HTTP 请求/响应，拦截参数	app.services , app.schemas
app.services	核心逻辑。如增删改查逻辑、事件处理逻辑、Agent流式客户端(sse_consumer.py)	app.models , app.schemas , app.db
app.schemas	Pydantic 数据验证模型，包含 REST 定义以及 Event JSON 结构	仅依赖基础 Python 和 Pydantic
app.models	SQLAlchemy 声明式实体，映射数据库表设计	app.db.base
app.db	核心数据库引擎构建及 SQLAlchemy 会话管理（Session）	app.core （取配置）
app.core	全局依赖与配置(config.py)，环境变量解析等	无


开发包图：



4.2 运行时进程

系统的运行时主要依托单个 ASGI Web 服务进程（如 Uvicorn），内部逻辑大量使用 Asyncio 协程控制非阻塞 IO（主要是对外部 Agent 的 SSE 连接和数据库交互）。


进程图（核心任务提交流程）：



4.3 物理部署

本系统为典型的无状态后端服务器，通过文件系统或独立的 RDBMS 与状态进行交互。

部署图：



5. 接口视角

5.1 模块的职责与层之间调用接口

以“评测任务流系统”为例说明分层之间的互动。

- **API模块层职责**：处理前端路由并返回格式化数据。
- **Service模块职责**：封装业务逻辑和第三方调用(如SSE处理)。
- **Model/DB模块职责**：进行SQL构建和状态事务持久化。
- **层之间调用接口（举例：执行一项评测任务）**：

- UI -> API: `POST /api/v1/tasks/{task_id}/execute`
- API -> Service: `execution_service.run_evaluation_task(db_session, task_id)`
- Service -> SSE Client: 包装请求调用
`sse_consumer.consume_events(target_endpoint, payload_from_dataset)` 挂载到后台协程。
- Service -> DAO: `db_session.add(trace_log)`

5.2 用户界面层的分解

- * **5.2.1 职责**：对外暴露符合 OpenAPI 标准的路由。处理身份认证、JSON 序列化、字段必填基础校验。
- * **5.2.2 接口规范**：
 - * `GET /api/v1/datasets/` - 获取所有数据集
 - * `GET /api/v1/tasks/{id}` - 获取任务状态
 - * 依靠 Pydantic 定义请求体和响应体，输出 `application/json`。

5.3 业务逻辑层的分解

- * **5.3.1 职责**：编排核心算法与逻辑流，验证关联外键是否存在，执行指标换算。核心难点在`sse\_consumer`解析长向连接中的半结构化 Chunk 数据。
- * **5.3.2 接口规范**：
 - * 入参均为 Python 基本类对象 (如 `TaskCreate` Schema 对象) 及 `Session`（以便进行事务级别控制）。
 - * 通过自定义 Exception (如 `HTTPException` 或更底层的 `RecordNotFoundException`) 中断并向 API 层进行异常抛出。

5.4 数据层的分解

- * **5.4.1 职责：**剥离业务逻辑和具体的 SQL 语句结构，提供干净的 CRUD 仓储接口，隔离不同 SQL 方言。
- * **5.4.2 接口规范：**完全融入 SQLAlchemy (Session.execute, Session.commit)。通过 `Base` 基类实现基础关联。

6. 信息视角

系统数据库采用关系型数据库。以下列出核心持久化对象（PO）及其表设计。暂时使用文件系统作为数据库，后期替换成实际的数据库。

6.1 描述数据持久化对象(PO)

- AgentVersion (Agent配置对象):** 定义被测 Agent 的 HTTP 目标、权限凭证、模型配置细节。
- Dataset & DatasetItem (数据集及用例):** 定义评测用的输入原文数据及标注参考答案。
- Task (评测任务主题):** 绑定指定的 Agent 和 Dataset，并设置评估的指标模式（如准确率、召回率）以及总体运行进度。
- TraceLog (评测事件记录):** 用于 SSE 流中接收到的 Thinking及 Tool_Call详情存储，支持后期追溯和复盘分析。
- Annotation (最终结果):** 专门存放 Agent 最终输出。

6.2 数据库表信息

以下提供核心表结构的概要展示：

表 1：`agent\_versions` （Agent 版本模型）

字段名称	数据类型	约束条件	说明
id	VARCHAR(50)	PK, Index	主键 UUID
name	VARCHAR(200)	NOT NULL, Unique	配置名称
status	VARCHAR(20)	DEFAULT 'ACTIVE'	启用状态 (ACTIVE/INACTIVE/ARCH

			IVED)
config	JSON	NOT NULL	核心配置，包括 api_endpoint 等
created_at	DATETIME	DEFAULT NOW	创建时间

表 2：`eval\_tasks`（评测任务模型）

字段名称	数据类型	约束条件	说明
id	VARCHAR(50)	PK, Index	主键 UUID
name	VARCHAR(200)	NOT NULL	任务展示名称
agent_version_id	VARCHAR(50)	FK Index	关联 agent_versions.id
dataset_id	VARCHAR(50)	FK Index	关联 datasets.id
status	VARCHAR(20)	DEFAULT 'pending'	pending/running/completed/failed
progress	FLOAT	0.0 - 1.0	执行进度百分比
evaluation_config	JSON	NOT NULL	评分计算配置
result_summary	JSON	NULL	任务完结后自动汇聚的总分和统计指标

表 3：`eval\_trace\_logs`（日志流表，高频插入）

字段名称	数据类型	约束条件	说明
id	INTEGER	PK AutoInc	自增主键
execution_id	VARCHAR(50)	FK Index	所属的运行批次ID
event_type	VARCHAR(20)	NOT NULL	thinking / tool_call / error
content	JSON	NOT NULL	

			Agent SSE 吐出的该事件原始载荷
timestamp	DATETIME	DEFAULT NOW	事件发生的时间界限

表 4：`datasets`（数据集模型）

字段名称	数据类型	约束条件	说明
id	VARCHAR(50)	PK, Index	主键 UUID
name	VARCHAR(200)	NOT NULL	数据集名称
description	TEXT	NULL	数据集备注描述
type	ENUM	NOT NULL	数据集类型，如 TEXT_SCAN, CLAIM_VERIFY
schema_config	JSON	NOT NULL	数据集结构定义JSON Schema
size	INTEGER	DEFAULT 0	包含的测试用例数量
usage_count	INTEGER	DEFAULT 0	被引用的次数
metadata	JSON	DEFAULT {}	其他元数据
created_at	DATETIME	DEFAULT NOW	创建时间
updated_at	DATETIME	ON UPDATE NOW	修改时间

表 5：`dataset\_items`（测试用例详情模型）

字段名称	数据类型	约束条件	说明
id	VARCHAR(50)	PK, Index	主键 UUID
dataset_id	VARCHAR(50)	FK Index	关联对应 datasets.id
input_data	JSON	NOT NULL	测试用例输入配置数据

<code>expected_output</code>	JSON	NULL	Agent应该输出的理论内容
<code>reference</code>	JSON	NULL	人工标注的标准答案辅助信息
<code>metadata</code>	JSON	DEFAULT {}	元数据
<code>created_at</code>	DATETIME	DEFAULT NOW	创建时间
<code>updated_at</code>	DATETIME	ON UPDATE NOW	修改时间

表 6: `executions` (评测单次执行记录模型)

字段名称	数据类型	约束条件	说明
<code>id</code>	VARCHAR(50)	PK, Index	主键 UUID
<code>task_id</code>	VARCHAR(50)	FK Index	关联的任务 <code>eval_tasks.id</code>
<code>name</code>	VARCHAR(200)	NULL	执行记录可读名
<code>status</code>	VARCHAR(20)	DEFAULT 'pending'	状态: pending, running, completed, failed, stopped
<code>progress</code>	FLOAT	0.0 - 1.0	进度的百分比
<code>total_cases</code>	INTEGER	DEFAULT 0	执行的总用例个数
<code>completed</code>	INTEGER	DEFAULT 0	已完成的用例个数
<code>pending_cases</code>	INTEGER	DEFAULT 0	等待执行个数
<code>passed_cases</code>	INTEGER	DEFAULT 0	测试通过个数
<code>failed_cases</code>	INTEGER	DEFAULT 0	测试失败个数
<code>skipped_cases</code>	INTEGER	DEFAULT 0	跳过执行的个数
<code>performance_metrics</code>	JSON	DEFAULT {}	性能相关指标: 平均耗时/流控用量
<code>result_summary</code>	JSON	NULL	并发执行完成时的聚合评分缓存

errors	JSON	DEFAULT []	执行过程错误信息合集
duration	FLOAT	NULL	执行总耗时(秒)
started_at	DATETIME	DEFAULT NOW	真正开始运转时间
completed_at	DATETIME	NULL	判断状态完毕时的时间界限

表 7：`execution\_cases`（单条测试用例执行实例表）

字段名称	数据类型	约束条件	说明
id	INTEGER	PK AutoInc	自增主键
execution_id	VARCHAR(50)	FK Index	归属的执行批次 executions.id
case_id	VARCHAR(50)	FK Index	测试样例对应的 dataset_items.id
status	VARCHAR(20)	DEFAULT 'pending'	pending, running, passed, failed, skipped
input_data	JSON	NOT NULL	此条的请求参数载体
output_data	JSON	NULL	实际的机器返回
expected_output	JSON	NULL	预先定义的结果
execution_details	JSON	DEFAULT {}	拆解出的 Agent 推理步骤/响应时间和 tokens 消耗等
evaluation_results	JSON	DEFAULT {}	各评估方法的最终打分/评价结论
error	TEXT	NULL	Agent 或系统抛出的错误摘要
started_at	DATETIME	DEFAULT NOW	单条用例开始执行时间
completed_at	DATETIME	NULL	单条用例结束界限

表 8: `eval\_annotations` (Agent 返回评测判定结果模型)

字段名称	数据类型	约束条件	说明
id	INTEGER	PK AutoInc	自增主键
execution_id	VARCHAR(50)	FK Index	归属批次 executions.id
claim_id	VARCHAR(50)	Index, NOT NULL	问题/声明项标识 ID
text	TEXT	NOT NULL	句子源文本内容
start_offset	INTEGER	NULL	字符起始位 (用于高亮)
end_offset	INTEGER	NULL	字符终点位 (用于高亮)
error_type	VARCHAR(50)	NULL	实体分类/谬误类型标签
confidence	FLOAT	NULL	模型决策置信度百分位
reasoning	TEXT	NULL	决策理由说明 (Chain of Thinking)
evidence_urls	JSON	DEFAULT []	寻找到的影响源URL证据链接
timestamp	DATETIME	DEFAULT NOW	收到回传的判定结果的时间