


Agent评估系统 需求点映射文档

1. 评测任务管理能力

支持创建评测任务，支持配置评测任务（如Agent版本、数据集选择、评测方法选择等），支持评测任务增删改查和状态管理与展示



Agent 版本管理

注册与管理被测 Agent 的版本信息、配置参数及生命周期状态

[+ 注册新版本](#)

筛选状态

共 3 个版本

ACTIVE2026/05/11 claude 暂无描述 模型claude-opus-4.7 端点http://127.0.0.1:8080/v1/run 1 可用 评测引用 状态 查看详情 删除	ACTIVE2026/05/11 glm-4-flash 用于检测E2E的查验 模型glm-4-flash 端点http://127.0.0.1:8081/analyze 1 可用 评测引用 状态 查看详情 删除	ACTIVE2026/05/18 FactCheck-test1 用于检测端到端的实施查验 模型claude-opus-4.7 端点http://127.0.0.1:8080/analyze 6 可用 评测引用 状态 查看详情 删除
--	--	--

Agent 版本管理

注册与管理被测 Agent 的版本信息、配置参数及生命周期状态

筛选状态

[+ 注册新版本](#)

共 3 个版本

ACTIVE2026/05/11 claude 暂无描述 模型claude-opus-4.7 端点http://127.0.0.1:8080/v1/run 1 可用 评测引用 状态 查看详情 删除	ACTIVE2026/05/11 glm-4-flash 用于检测E2E的查验 模型glm-4-flash 端点http://127.0.0.1:8081/analyze 1 可用 评测引用 状态 查看详情 删除	ACTIVE2026/05/18 FactCheck-test1 用于检测端到端的实施查验 模型claude-opus-4.7 端点http://127.0.0.1:8080/analyze 6 可用 评测引用 状态 查看详情 删除
--	--	--

版本名称 *

例如: FactCheck-Sonnet-V1

描述

该版本的详细描述或实验背景 (可选)

初始状态 *

ACTIVE — 可用

核心配置 (JSON) *

```
{  "api_endpoint": "http://agent-service:8080/api/v1/verify",  "model_name": "claude-opus-4.7",  "temperature": 0,  "max_steps": 6,  "reflexion_enabled": false}
```

元数据 (JSON, 可选)

{}

取消

注册

评估策略

管理系统内置评估指标，及注册自定义 Prompt / 脚本评估方法

+ 注册自定义指标

请选择

请选择

请选择

共 6 项指标

EFFECTIVENESS

2026/05/10

E2E-SSEChecker

检查toolcall的准确度

★ 模型评分 ✨ 面向过程 (Process) 输出: SCORE_0_1

查看配置

EFFECTIVENESS

内置

2026/05/10

Ragas - Faithfulness

评估 Agent 的输出是否忠实于输入的 Context，而不包含幻觉。

★ 模型评分 ✨ 面向结果 (Result) 输出: SCORE_0_1

查看配置

EFFECTIVENESS

内置

2026/05/10

Ragas - Answer Relevancy

评估 Agent 的回答是否切题，相关性有多高。

★ 模型评分 ✨ 面向结果 (Result) 输出: SCORE_0_1

查看配置

PERFORMANCE

内置

2026/05/10

Ragas - Context Precision

评估 Agent 从长上下文中提取有效信息的精准度。

★ 模型评分 ✨ 面向结果 (Result) 输出: SCORE_0_1

查看配置

EFFECTIVENESS

2026/05/10

E2ENotation

暂无描述

★ 模型评分 ✨ 面向结果 (Result) 输出: BOOL

查看配置

EFFECTIVENESS

2026/05/10

E2EChecker

用于评估端到端的事实检验

★ 模型评分 ✨ 面向结果 (Result) 输出: TEXT

查看配置

评测任务

组合智能体、数据集与指标，

COMPLETED

final-eval3

无描述

100%

查看配置与运行记录

COMPLETED

SSE-eval

评估toolcall覆盖

100%

查看配置与运行记录

COMPLETED

test2

创建静态评测任务

任务名称 *

eval

简单描述

sse-checking

目标智能体 (AGENT) *

FactCheck-test1

评测数据集 (DATASET) *

factcheck_evalv2 [E2E_FACT_CHECK]

勾选测试指标 (Evaluation Config)

Process Evaluation (SSE/Steps)

☐ E2E-SSEChecker
EFFECTIVENESS | 自定义

Result Evaluation (Final Output)

☐ Ragas - Faithfulness
EFFECTIVENESS | 内置

☐ Ragas - Context Precision
PERFORMANCE | 内置

☒ E2EChecker
EFFECTIVENESS | 自定义

☒ Ragas - Answer Relevancy
EFFECTIVENESS | 内置

☐ E2ENotation
EFFECTIVENESS | 自定义

+ 创建任务


05/11 08:02

0 条验证

05/10 13:17

0 条验证

05/10 07:03



- 在任务配置界面，可以任意搭配之前配置好的数据集、agent版本、数据集。
- 同时可以看到该任务的多个execution

2. 评测执行与方法能力

支持多种评测方法（三种划分不独立，相互间必然有重叠）

按评估模式划分：面向结果（只关注输入输出）/ 面向过程（关注 Agent 响应的中间过程）


按评估方式划分：显式指标（可以明确计算，如 Token 消耗、工具调用正确率、任务成功率、响应时间等）/ 模糊指标（评价标准相对主观，一般以 LLM-as-a-Judge 的模式实现，例如推理质量、输出内容准确性、幻觉程度、交互体验等，可以自行设计，也可以基于已有评估框架实现）

按评估维度划分：效果维度（任务响应是否有效、准确、完整）/ 安全（反馈信息是否安全，是否不包含有害内容）/ 性能（用户体验是否流畅，是否出现长时间停顿等待，是否有良好的互动交流体验）



- 我们有内置三个面向结果的ragas评估策略。
- 支持自定义策略，可以选择评估维度和计算模式，自定义LLM的prompt。


扩展能力：支持自定义评估指标，支持组合评估策略



- 在任务配置界面，我们可以任意数量勾选评估策略。
- 在分析界面可以看到每个评估策略的输出，用作反馈。


3. 评测分析与展示能力

支持单次评估任务可视化结果展示，支持多个评估任务间对比分析与展示



CROSS-EXECUTION COMPARISON

Analyzing 2 targets

[← 回到控制台](#)

TARGET	E2ENOTATION	E2E-SSECHECKER
39ff21e0-8517-46ea-a388-b1311781fc49	0.85	0.85

- 我们可以深入查看每一次执行结果的详细输入输出以及中间过程。
- 同时可以选择多个运行序号进行柱状图对比。