

# 网页文章错误检测Agent及评估平台-需求分析文档

## 1. 引言

### 1.1 项目背景

在信息爆炸时代，网页文章中常夹杂事实性错误、逻辑谬误或缺乏支撑的断言。本项目旨在开发一款基于大语言模型（LLM）的网页文章错误检测 Agent（浏览器插件），能够在用户阅读时实时检测并标注可疑内容；同时，为了科学衡量 Agent 的能力，配套开发一套独立的 Agent 评估平台。

### 1.2 系统范围

本项目由两个核心子系统构成：

- Agent 应用系统（To-C端）**：包含 Chrome 浏览器插件、FastAPI 后端、Agent 推理核心（基于 ReAct + Plan-and-Execute + Reflexion 架构）及四大外部工具链。
- Agent 评估平台（To-D端）**：包含评测任务管理后端（集成 Ragas 及 LLM-as-a-Judge）、测试数据集及数据可视化前端。

## 2. 角色及用例分析


### 2.1 系统角色定义

**普通用户 (Reader)**：使用浏览器插件阅读文章，查看错误检测结果的用户。

**评测人员 (Evaluator)**：项目开发者或测试者，使用评估平台测试 Agent 性能。

**外部系统 (External Systems)**：LLM API (如 Claude/GPT-4o)、搜索引擎 (Tavily/DuckDuckGo)、维基百科 API 等。

### 2.2 核心用例图



## 3. 功能需求

### 3.1 Agent应用子系统

#### 3.1.1 网页内容获取与交互前端

- **内容提取**：利用 @mozilla/readability 自动剥离广告、导航栏，精准提取当前网页的文章正文及段落结构。
- **SSE 实时流处理**：通过 Server-Sent Events 接收后端推送的 Agent 推理状态，实现流式反馈。
- **DOM 高亮注入**：在不破坏原网页样式的前提下（使用 Shadow DOM 隔离），通过 TreeWalker 定位目标文本并用 <mark> 标签包裹。按错误类型赋予不同颜色。
- **Tooltip 悬浮窗**：鼠标悬浮高亮文本时，展示错误类型、置信度进度条、简短推理摘要和外部证据链接。
- **侧边栏 (Side Panel)**：实时追加 Agent 的 ReAct 推理步骤（Thought → Action → Observation），并展示全局分析进度。


#### 3.1.2 Agent推理核心

基于状态机模型，Agent 具备以下复杂推理能力：

- **Plan-and-Execute (规划与执行)**：扫描全文，提取“值得验证的声明”，按可疑程度排序并生成验证计划。

- **ReAct 循环**：对单条声明进行“思考-行动-观察”循环，动态调度外部工具，直至置信度达标或达到最大迭代轮次。
- **Reflexion (反思机制)**：当验证结论的置信度低于阈值（如 0.7）时，触发二次自我反思与修正。

3.1.3 Agent运行 workflow



3.1.4 工作链需求

- **网络搜索 (web\_search)**：主用 Tavily API，超时或失败时无缝降级至 DuckDuckGo。
- **维基百科 (wikipedia\_lookup)**：支持中英双语检索自动切换。
- **来源验证 (source\_verifier)**：爬取给定的 URL 并提取摘要信息。
- **内部矛盾检测 (cross\_reference)**：本地运行 paraphrase-multilingual-MiniLM 模型预计算全文档句子向量，利用余弦相似度检索相关句，再交由 LLM 判别内部矛盾。

3.2 Agent评估平台子系统

### 3.2.1 任务管理


- 支持创建、查看、修改（仅 Pending 状态）、删除和启动评测任务。
- 支持选择不同的测试数据集和不同的 Agent 版本。

### 3.2.2 评测指标计算体系

平台需支持显式指标与隐式（模糊）指标的结合：

- **显式指标：**Token 消耗量、平均响应时间、工具调用成功率、标注准确率（Precision/Recall/F1）。
- **模糊指标 (基于 Ragas 与 LLM-as-a-Judge)：**
  - *推理质量评分：* Agent 思维链的逻辑连贯性。
  - *幻觉程度评分：* 判断判定结果是否严格基于工具观察（Observation）。
  - *交互体验评分：* 输出摘要的可读性。

### 3.2.3 评测任务状态流转



### 3.2.4 结果可视化与对比分析前端

- **任务详情页：**通过雷达图（ECharts）展示多维指标得分，并以时间线组件还原 Agent 每一步的推理链（Trace）。
- **多版本对比：**支持勾选 2-4 个任务进行横向对比，高亮显示提升（绿色）或下降（红色）的指标，通过折线/柱状图展示能力演进趋势。

## 4. 非功能需求

## 4.1 性能需求

- **响应时效性**：分析接口必须使用 SSE 流式输出，用户点击开始后，首个推理状态返回时间应 < 2 秒。
- **本地模型性能**：cross\_reference 使用的本地向量模型需进行批处理 (Batch Processing) 优化，文章向量预计算应在 < 5秒 内完成。

## 4.2 可靠性需求


- **容错机制**：所有外部 API 调用 (Tavily, Wiki, HTTP请求) 必须设置 10 秒超时，且最多重试 3 次。
- **异常隔离**：工具执行抛出异常时必须在内部捕获，转化为标准的错误字符串返回给 Agent (如 "工具执行失败：...")，严禁导致后端进程崩溃。

## 4.3 安全需求

- **密钥管理**：绝对禁止在前后端代码中硬编码 LLM 或搜索 API 的 Key。必须通过环境变量 .env 注入，且 .env 必须加入 .gitignore。
- **样式安全**：浏览器插件注入 DOM 时必须使用 Shadow DOM，防止插件 CSS 被目标网站污染，或插件 CSS 破坏目标网站原有排版。

## 5. 数据模型需求

评估平台需要持久化评测数据，以下为评估平台后端的实体关系核心模型：



- **数据交互契约**：插件前端、后端与评估平台之间，必须严格遵循技术负责人定义的统一 JSON Schema（包含 annotation, thinking, tool\_call 等事件类型）。